

Семинар 11.

Ошибки спецификации модели.

1. (Исключение существенных переменных) Дана стандартная модель парной регрессии

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i, \quad i = 1, \dots, n.$$

- (а) Чему равна МНК-оценка коэффициента β_2 при ограничении $\beta_1 = 0$.
 (б) Чему равна дисперсия оценки в пункте (а)? Покажите, что она меньше, чем $\sigma^2 / \sum_{i=1}^n (x_i - \bar{x})^2$ — дисперсия МНК-оценки β_2 в регрессии без ограничения. Противоречит ли это теореме Гаусса–Маркова?

Решение:

- (а) GDP (истинный процесс): $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i, \quad i = 1, \dots, n.$

Модель, которую оцениваем: $y_i = \beta_2 x_i + \varepsilon_i, \quad i = 1, \dots, n.$

Найдем МНК-оценку для нашей модели:

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}.$$

Как известно, при пропуске существенных переменных (в нашем случае пропущена константа) МНК-оценки смещены. Убедимся в этом:

$$\begin{aligned} \mathbb{E}(\hat{\beta}_2) &= \mathbb{E}\left(\frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}\right) = \mathbb{E}\left(\frac{\sum_{i=1}^n (\beta_1 + \beta_2 x_i + \varepsilon_i) x_i}{\sum_{i=1}^n x_i^2}\right) = \\ &= \beta_1 \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2} + \beta_2 \neq \beta_2. \end{aligned}$$

Таким образом, МНК-оценка действительно смещённая.

- (б) Вычислим дисперсию данной оценки:

$$\begin{aligned} \text{Var}(\hat{\beta}_2) &= \text{Var}\left(\frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}\right) = \text{Var}\left(\frac{\sum_{i=1}^n \varepsilon_i x_i}{\sum_{i=1}^n x_i^2}\right) = \frac{1}{(\sum_{i=1}^n x_i^2)^2} \sum_{i=1}^n x_i^2 \text{Var}(\varepsilon_i) = \\ &= \frac{1}{(\sum_{i=1}^n x_i^2)^2} \sum_{i=1}^n x_i^2 \sigma^2 = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}. \end{aligned}$$

Сравним данную дисперсию с дисперсией МНК-оценки параметра β_2 для истинной модели (обозначим эту оценку как β_2^{true} которая, как нам известно, имеет вид:

$$\text{Var}(\beta_2^{\text{true}}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Сравним знаменатели:

$$\sum_{i=1}^n x_i^2 - \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i^2 + n(\bar{x})^2 = n(\bar{x})^2 \geq 0.$$

Следовательно, МНК-оценка в модели с пропущенной константой имеет меньшую дисперсию. Однако это не противоречит теореме Гаусса–Маркова. Согласно теореме Гаусса–Маркова МНК-оценка β_2^{true} в истинной модели действительно имеет минимальную дисперсию, однако, в классе линейных по y и несмещённых оценок, но МНК-оценка β_2 в модели с пропущенной константой является смещённой.

2. (Включение лишних переменных) Пусть процесс, порождающий данные, имеет вид:

$$y = X\beta + \varepsilon. \quad (1)$$

Модель, которую мы оцениваем:

$$y = X\beta + Z\gamma + \varepsilon. \quad (2)$$

Здесь X — $n \times k$ матрица, Z — $n \times l$ матрица, y — $n \times 1$ вектор, β — $k \times 1$ вектор, γ — $l \times 1$ вектор, ε — $n \times 1$ вектор.

- (а) Будет ли МНК-оценка вектора параметров β несмещённой?
- (б) Что произойдёт с оценкой ковариационной матрицы $\widehat{\text{Var}}(\hat{\beta})$?
- (в) Будет ли несмещённой МНК-оценка дисперсии случайной ошибки σ^2 ?

Решение:

- (а) Вычислим оценку вектора β по модели (2) (достаточно вспомнить формулу из Задачи 3 из КР-1).

$$\hat{\beta} = (X'M_z X)^{-1} X'M_z y, \text{ где } M_z = I - Z(Z'Z)^{-1}Z'.$$

Проверим, является ли данная МНК-оценка несмещённой:

$$\begin{aligned} \mathbb{E}(\hat{\beta}) &= \mathbb{E}[(X'M_z X)^{-1} X'M_z y] = \mathbb{E}[(X'M_z X)^{-1} X'M_z (X\beta + \varepsilon)] = \\ &= (X'M_z X)^{-1} X'M_z X\beta + (X'M_z X)^{-1} X'M_z \mathbb{E}(\varepsilon) = \beta. \end{aligned}$$

Следовательно, при включении лишних переменных МНК-оценка вектора параметров β остаётся несмещённой.

(б) Рассчитаем ковариационную матрицу для оценки $\hat{\beta}$:

$$\begin{aligned}\text{Var}(\hat{\beta}) &= \text{Var} \left[(X' M_z X)^{-1} X' M_z y \right] = \text{Var} \left[(X' M_z X)^{-1} X' M_z (X\beta + \varepsilon) \right] = \\ &= (X' M_z X)^{-1} X' M_z \text{Var}(X\beta + \varepsilon) M_z X (X' M_z X)^{-1} = \\ &= (X' M_z X)^{-1} X' M_z \text{Var}(\varepsilon) M_z X (X' M_z X)^{-1} = \sigma^2 \left((X' M_z X)^{-1} X' M_z M_z X (X' M_z X)^{-1} \right) = \\ &= \sigma^2 (X' M_z X)^{-1}.\end{aligned}$$

Для истинной модели ковариационная матрица для МНК-оценки вектора параметров β имеет вид:

$$\text{Var}(\hat{\beta}^{true}) = \sigma^2 (X' X)^{-1}.$$

Сравним данные ковариационные матрицы, рассчитав разницу между ними

$$\text{Var}(\hat{\beta}^{true}) - \text{Var}(\hat{\beta}).$$

Вместо разности выше рассмотрим разность

$$\begin{aligned}\left[\text{Var}(\hat{\beta}^{true}) \right]^{-1} - \left[\text{Var}(\hat{\beta}) \right]^{-1} &= \frac{1}{\sigma^2} (X' X) - \frac{1}{\sigma^2} (X' M_z X) = \frac{1}{\sigma^2} (X' X - X' M_z X) = \\ &= \frac{1}{\sigma^2} (X' X - X' (I - P_z) X) = \frac{1}{\sigma^2} (X' X - X' X + X' P_z X) = \frac{1}{\sigma^2} (X' P_z X) > 0.\end{aligned}$$

Тогда

$$\text{Var}(\hat{\beta}^{true}) - \text{Var}(\hat{\beta}) < 0,$$

что означает, что дисперсия оценки будет увеличиваться.

(в) Нам известно, что оценка дисперсии ошибки в модели (2) равна:

$$\hat{\sigma}^2 = \frac{RSS}{n - k - l}.$$

Проверим, будет ли она несмещённой:

$$\mathbb{E} \left(\frac{RSS}{n - k - l} \right) = \frac{1}{n - k - l} \mathbb{E}(RSS).$$

Запишем RSS в модели (2) в матричном виде:

$$RSS = y' M^* y,$$

где M^* — матрица оператор ортогонального проектирования на подпространство, образованное X и Z , то есть $M^* X = M^* Z = 0$.

$$RSS = y'M^*y = (X\beta + \varepsilon)'M^*(X\beta + \varepsilon) = \varepsilon'M^*\varepsilon \text{ так как } M^*X = 0.$$

Обозначим через $X^* = [X \ Z]$ матрицу размерности $n \times (k+l)$, содержащую все объясняющие показатели. Тогда

$$\begin{aligned} \mathbb{E}(RSS) &= \mathbb{E}(\varepsilon'M^*\varepsilon) = \mathbb{E}(\text{tr}(\varepsilon'M^*\varepsilon)) = \mathbb{E}(\text{tr}(\varepsilon'M^*\varepsilon)) = \mathbb{E}(\text{tr}(\varepsilon\varepsilon'M^*)) = \\ &= \text{tr}(M^*\mathbb{E}(\varepsilon\varepsilon')) = \sigma^2\text{tr}(M^*) = \sigma^2\text{tr}(I - X^*(X^{*'}X^*)^{-1}X^{*'}) = \\ &= \sigma^2\text{tr}(I_n) - \sigma^2\text{tr}(X^*(X^{*'}X^*)^{-1}X^{*'}) = \sigma^2n - \sigma^2\text{tr}(X^{*'}X^*(X^{*'}X^*)^{-1}) = \\ &= \sigma^2n - \sigma^2\text{tr}(I_{k+l}) = \sigma^2(n - k - l). \end{aligned}$$

Для вывода $\mathbb{E}(RSS)$ мы воспользовались тем, что $\varepsilon'M^*\varepsilon$ — скаляр, который можно рассматривать как матрицу размерности 1×1 , след которой и есть этот скаляр. Затем использовали свойство следа $\text{tr}(A \cdot B) = \text{tr}(B \cdot A)$. Таким образом, получаем:

$$\mathbb{E}\left(\frac{RSS}{n - k - l}\right) = \frac{1}{n - k - l}\mathbb{E}(RSS) = \sigma^2,$$

то есть оценка дисперсии ошибки является несмещённой при включении в модель лишних переменных.

3. Для 400 голландских магазинов модной одежды с помощью трёх моделей оценили зависимость продаж в расчете на квадратный метр в гульденах, $Sales$, от:

- общей площади магазина, $Size$, в m^2 ;
- количества сотрудников, работающих целый день, $Nfull$;
- количества временных рабочих, $Ntemp$;
- дамми-переменной $Owner$, равной единице, если собственник один, и нулю иначе.

$$\widehat{Sales}_i = 6083 - 15.25Size_i + 1452.8Nfull_i + 420.15Ntemp_i - 1464.1Owner_i$$

(718) (1.59) (171) (423) (361)

$$\ln \widehat{Sales}_i = 8.59 - 0.0024Size_i + 0.183Nfull_i + 0.102Ntemp_i - 0.209Owner_i$$

(0.11) (0.00024) (0.026) (0.066) (0.056)

$$\ln \widehat{Sales}_i = 10.08 - 0.31 \ln Size_i + 0.22 \ln Nfull_i + 0.066 \ln Ntemp_i - 0.19 \ln Owner_i$$

(0.21) (0.043) (0.061) (0.118) (0.059)

В скобках приведены стандартные ошибки.

(а) Дайте интерпретацию коэффициента при переменной $Size$ в каждой из трёх моделей;

(б) Подробно опишите, как выбрать наилучшую из этих моделей.

4. По данным для 23 демократических стран оценили зависимость индекса Джини от ВВП на душу населения с учетом ППС (паритета покупательной способности). Затем провели тест Рамсея.

```
. reg gini gdp if democ==1
```

Source	SS	df	MS	Number of obs = 23		
Model	506.853501	1	506.853501	F(1, 21) =	13.05	
Residual	815.572523	21	38.8367868	Prob > F =	0.0016	
				R-squared =	0.3833	
				Adj R-squared =	0.3539	
Total	1322.42602	22	60.1102738	Root MSE =	6.2319	

gini	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
gdp	-.0006307	.0001746	-3.61	0.002	-.0009937	-.0002676
_cons	44.30983	3.572733	12.40	0.000	36.87993	51.73974

```
. ovtest
```

```
Ramsey RESET test using powers of the fitted values of gini
Ho: model has no omitted variables
F(3, 18) = 5.16
Prob > F = 0.0095
```

- (а) Сформулируйте нулевую и альтернативную гипотезу теста Рамсея.
- (б) Опишите пошагово, как проводится тест Рамсея.
- (в) Прокомментируйте результаты теста Рамсея.