Семинар 11.
Ошибки спецификации модели.

1. (Исключение существенных переменных) Дана стандартная модель парной регрессии

$$y_i = \beta_1 + \beta_2 x_i + \varepsilon_i,\ i = 1, ..., n.$$

   (а) Чему равна МНК–оценка коэффициента β_2 при ограничении $\beta_1 = 0$.

   (б) Чему равна дисперсия оценки в пункте (а)? Покажите, что она меньше, чем $\sigma^2 / \sum_{i=1}^n (x_i - \bar{x})^2$ — дисперсия МНК–оценки β_2 в регрессии без ограничения. Противоречит ли это теореме Гаусса–Маркова?

   Решение:

   (а) GDP (истинный процесс): $y_i = \beta_1 + \beta_2 x_i + \varepsilon_i,\ i = 1, ..., n.$
   Модель, которую оцениваем: $y_i = \beta_2 x_i + \varepsilon_i,\ i = 1, ..., n.$
   Найдем МНК–оценку для нашей модели:

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}.$$

   Как известно, при пропуске существенных переменных (в нашем случае пропущена константа) МНК–оценки смещены. Убедимся в этом:

$$\mathbb{E}(\hat{\beta}_2) = \mathbb{E}\left(\frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}\right) = \mathbb{E}\left(\frac{\sum_{i=1}^n (\beta_1 + \beta_2 x_i + \varepsilon_i) x_i}{\sum_{i=1}^n x_i^2}\right) =$$

$$= \beta_1 \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n x_i^2} + \beta_2 \neq \beta_2.$$

   Таким образом, МНК–оценка действительно смещённая.

   (б) Вычислим дисперсию данной оценки:

$$\mathrm{Var}(\hat{\beta}_2) = \mathrm{Var}\left(\frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2}\right) = \mathrm{Var}\left(\frac{\sum_{i=1}^n \varepsilon_i x_i}{\sum_{i=1}^n x_i^2}\right) = \frac{1}{\left(\sum_{i=1}^n x_i^2\right)^2} \sum_{i=1}^n x_i^2 \mathrm{Var}(\varepsilon_i) =$$

$$= \frac{1}{\left(\sum_{i=1}^n x_i^2\right)^2} \sum_{i=1}^n x_i^2 \sigma^2 = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}.$$

   Сравним данную дисперсию с дисперсией МНК–оценки параметра β_2 для истинной модели (обозначим эту оценку как β_2^{true} которая, как нам известно, имеет вид:

$$\mathrm{Var}(\beta_2^{true}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

Сравним знаменатели:

$$\sum_{i=1}^{n} x_i^2 - \sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - \sum_{i=1}^{n} x_i^2 + n(\bar{x})^2 = n(\bar{x})^2 \geq 0.$$

Следовательно, МНК–оценка в модели с пропущенной константой имеет меньшую дисперсию. Однако это не противоречит теореме Гаусса–Маркова. Согласно теореме Гаусса–Маркова МНК–оценка β_2^{true} в истинной модели действительно имеет минимальную дисперсию, однако, в классе линейных по y и несмещённых оценок, но МНК–оценка β_2 в модели с пропущенной константой является смещённой.

2. (Включение лишних переменных) Пусть процесс, порождающий данные, имеет вид:

$$y = X\beta + \varepsilon. \ (1)$$

Модель, которую мы оцениваем:

$$y = X\beta + Z\gamma + \varepsilon. \ (2)$$

Здесь X — $n \times k$ матрица, Z — $n \times l$ матрица, y — $n \times 1$ вектор, β — $k \times 1$ вектор, γ — $l \times 1$ вектор, ε — $n \times 1$ вектор.

(а) Будет ли МНК–оценка вектора параметров β несмещённой?

(б) Что произойдёт с оценкой ковариационной матрицы $\widehat{\mathrm{Var}}(\hat{\beta})$?

(в) Будет ли несмещённой МНК–оценка дисперсии случайной ошибки σ^2?

Решение:

(а) Вычислим оценку вектора β по модели (2) (достаточно вспомнить формулу из Задачи 3 из КР-1).

$$\hat{\beta} = \big(X'M_zX\big)^{-1}X'M_zy, \text{где } M_z = I - Z(Z'Z)^{-1}Z'.$$

Проверем, является ли данная МНК–оценка несмещённой:

$$\mathbb{E}(\hat{\beta}) = \mathbb{E}\left[\big(X'M_zX\big)^{-1}X'M_zy\right] = \mathbb{E}\left[\big(X'M_zX\big)^{-1}X'M_z(X\beta + \varepsilon)\right] =$$

$$= (X'M_zX)^{-1}X'M_zX\beta + \big(X'M_zX\big)^{-1}X'M_z\mathbb{E}(\varepsilon) = \beta.$$

Следовательно, при включении лишних переменных МНК–оценка вектора параметров β остаётся несмещённой.

(б) Рассчитаем ковариационную матрицу для оценки $\hat{\beta}$:

$$\mathrm{Var}(\hat{\beta}) = \mathrm{Var}\left[\left(X'M_zX\right)^{-1}X'M_zy\right] = \mathrm{Var}\left[\left(X'M_zX\right)^{-1}X'M_z(X\beta+\varepsilon)\right] =$$

$$= \left(X'M_zX\right)^{-1}X'M_z\mathrm{Var}(X\beta+\varepsilon)M_zX\left(X'M_zX\right)^{-1} =$$

$$= \left(X'M_zX\right)^{-1}X'M_z\mathrm{Var}(\varepsilon)M_zX\left(X'M_zX\right)^{-1} = \sigma^2\Big(X'M_zX\Big)^{-1}X'M_zM_zX\left(X'M_zX\right)^{-1} =$$

$$= \sigma^2\left(X'M_zX\right)^{-1}.$$

Для истинной модели ковариационная матрица для МНК–оценки вектора параметров β имеет вид:

$$\mathrm{Var}(\hat{\beta}^{true}) = \sigma^2(X'X)^{-1}.$$

Сравним данные ковариационные матрицы, рассчитав разницу между ними

$$\mathrm{Var}(\hat{\beta}^{true}) - \mathrm{Var}(\hat{\beta}).$$

Вместо разности выше рассмотрим разность

$$\Big[\mathrm{Var}(\hat{\beta}^{true})\Big]^{-1} - \Big[\mathrm{Var}(\hat{\beta})\Big]^{-1} = \frac{1}{\sigma^2}(X'X) - \frac{1}{\sigma^2}(X'M_zX) = \frac{1}{\sigma^2}(X'X - X'M_zX) =$$

$$= \frac{1}{\sigma^2}(X'X - X'(I-P_z)X) = \frac{1}{\sigma^2}(X'X - X'X + X'P_zX) = \frac{1}{\sigma^2}(X'P_zX) < 0.$$

Тогда

$$\mathrm{Var}(\hat{\beta}^{true}) - \mathrm{Var}(\hat{\beta}) > 0,$$

что означает, что дисперсия оценки будет увеличиваться.

(в) Нам известно, что оценка дисперсии ошибки в модели (2) равна:

$$\hat{\sigma}^2 = \frac{RSS}{n-k-l}.$$

Проверим, будет ли она несмещённой:

$$\mathbb{E}\left(\frac{RSS}{n-k-l}\right) = \frac{1}{n-k-l}\mathbb{E}(RSS).$$

Запишем RSS в модели (2) в матричном виде:

$$RSS = y'M^*y,$$

где M^* — матрица оператор ортогонального проектирования на подпространство, образованное X и Z, то есть $M^*X = M^*Z = 0$.

$$RSS = y'M^*y = (X\beta + \varepsilon)'M^*(X\beta + \varepsilon) = \varepsilon'M^*\varepsilon \text{ так как} M^*X = 0.$$

Обозначим через $X^* = [X\ Z]$ матрицу размерности $n \times (k+l)$, содержащую все объясняющие показатели. Тогда

$$\mathbb{E}(RSS) = \mathbb{E}(\varepsilon'M^*\varepsilon) = \mathbb{E}(tr(\varepsilon'M^*\varepsilon)) = \mathbb{E}(tr(\varepsilon'M^*\varepsilon)) = \mathbb{E}(tr(\varepsilon\varepsilon'M^*)) =$$

$$= tr(M^*\mathbb{E}(\varepsilon\varepsilon'))) = \sigma^2 tr(M^*) = \sigma^2 tr(I - X^*(X^{*\prime}X^*)^{-1}X^{*\prime}) =$$

$$= \sigma^2 tr(I_n) - \sigma^2 tr(X^*(X^{*\prime}X^*)^{-1}X^{*\prime})) = \sigma^2 n - \sigma^2 tr(X^{*\prime}X^*(X^{*\prime}X^*)^{-1}) =$$

$$= \sigma^2 n - \sigma^2 tr(I_{k+l}) = \sigma^2(n-k-l).$$

Для вывода $\mathbb{E}(RSS)$ мы воспользовались тем, что $\varepsilon'M^*\varepsilon$ — скаляр, который можно рассматривать как матрицу размерности 1×1, след которой и есть этот скаляр. Затем использовали свойство следа $tr(A \cdot B) = tr(B \cdot A)$. Таким образом, получаем:

$$\mathbb{E}\left(\frac{RSS}{n-k-l}\right) = \frac{1}{n-k-l}\mathbb{E}(RSS) = \sigma^2,$$

то есть оценка дисперсии ошибки является несмещённой при включении в модель лишних переменных.

3. Для 400 голландских магазинов модной одежды с помощью трёх моделей оценили зависимость продаж в расчете на квадратный метр в гульденах, $Sales$, от:

   - общей площади магазина, $Size$, в м^2;
   - количества сотрудников, работающих целый день, $Nfull$;
   - количества временных рабочих, $Ntemp$;
   - дамми-переменной $Owner$, равной единице, если собственник один, и нулю иначе.

$$\widehat{Sales_i} = \underset{(718)}{6083} - \underset{(1.59)}{15.25}Size_i + \underset{(171)}{1452.8}Nfull_i + \underset{(423)}{420.15}Ntemp_i - \underset{(361)}{1464.1}Owner_i$$

$$\widehat{\ln Sales_i} = \underset{(0.11)}{8.59} - \underset{(0.00024)}{0.0024}Size_i + \underset{(0.026)}{0.183}Nfull_i + \underset{(0.066)}{0.102}Ntemp_i - \underset{(0.056)}{0.209}Owner_i$$

$$\widehat{\ln Sales_i} = \underset{(0.21)}{10.08} - \underset{(0.043)}{0.31}\ln Size_i + \underset{(0.061)}{0.22}\ln Nfull_i + \underset{(0.118)}{0.066}\ln Ntemp_i - \underset{(0.059)}{0.19}\ln Owner_i$$

В скобках приведены стандартные ошибки.

   (a) Дайте интерпретацию коэффициента при переменной $Size$ в каждой из трёх моделей;

(б) Подробно опишите, как выбрать наилучшую из этих моделей.

4. По данным для 23 демократических стран оценили зависимость индекса Джини от ВВП на душу населения с учетом ППС (паритета покупательной способности). Затем провели тест Рамсея.

```
. reg  gini gdp if  democ==1
```

Source	SS	df	MS	Number of obs =	23
				F(1, 21) =	13.05
Model	506.853501	1	506.853501	Prob > F =	0.0016
Residual	815.572523	21	38.8367868	R-squared =	0.3833
				Adj R-squared =	0.3539
Total	1322.42602	22	60.1102738	Root MSE =	6.2319

gini	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
gdp	-.0006307	.0001746	-3.61	0.002	-.0009937	-.0002676
_cons	44.30983	3.572733	12.40	0.000	36.87993	51.73974

```
. ovtest

Ramsey RESET test using powers of the fitted values of gini
       Ho:  model has no omitted variables
                  F(3, 18) =      5.16
                  Prob > F =      0.0095
```

(а) Сформулируйте нулевую и альтернативную гипотезу теста Рамсея.

(б) Опишите пошагово, как проводится тест Рамсея.

(в) Прокомментируйте результаты теста Рамсея.